

Credit Fraud Detection — Model Report

Análise comparativa de modelos de Machine Learning

Gerado em: 2025-12-05 18:29:46 UTC — Autor: Kayke Andrade

Resumo do dataset

Dataset: Kaggle — Credit Card Fraud Detection. 284.807 transações. Classes altamente desbalanceadas (≈0.17% fraudes). Features V1–V28 (PCA) + Amount + Time.

Pré-processamento

Foram aplicados split 80/20 estratificado, normalização (StandardScaler) no conjunto de treino, e balanceamento com SMOTE aplicado somente ao treino. Os artefatos (scaler + arrays) foram salvos em data/processed e models/.

Comparação de métricas

Modelo	ROC-AUC	Recall	Precision
Logistic Regression (Tuned)	0.9755	0.5714	0.8235
Random Forest (Tuned)	0.9652	0.7959	0.8764
Gradient Boosting (Tuned)	0.9129	0.7449	0.7604
XGBoost (Tuned)	0.9758	0.6939	0.8947
LightGBM (Tuned)	0.5480	0.1735	0.0829

Sugestão de modelo para produção (baseado em ROC-AUC)

XGBoost (Tuned)

Gráficos comparativos




Figura: precision comparison




Figura: recall comparison




Figura: roc auc comparison

Conclusão automática

O modelo com melhor ROC-AUC foi **XGBoost (Tuned)**. O modelo com maior Recall foi **Random Forest (Tuned)**. O modelo mais preciso foi **XGBoost (Tuned)**. Observação: a escolha do modelo final deve considerar o trade-off entre Recall e Precision conforme o caso de uso de negócios. Em cenários de fraude, costuma-se priorizar Recall.